

Wojciech Typer
279730

Kody źródłowe zostały napisane w języku Rust. Wykresy zostały wygenerowane w Pythonie poprzez bibliotekę Matplotlib. Użyto generatora liczb pseudolosowych Mersenne Twister. Każdy kod źródłowy generuje dane liczbowe, a następnie zapisuje je do pliku tekstowego, z którego następnie generowany jest wykres.

Wszystkie dane zostały uzyskane poprzez generowania $d(n)$ i "pobierania" pozostałych potrzebnych danych podczas tego procesu.

Interpretacja wykresów:

1) $b(n)$ - z wykresu możemy odczytać, że wraz ze wzrostem ilości urn - n , liczba losowań do uzyskania pierwszej kolizji jest większa i rośnie w tempie \sqrt{n} (co można odczytać z wykresu $b(n) / \sqrt{n}$ - wartości średnie na tym wykresie można aproksymować do stałej różnej od zera). Wraz ze wzrostem ilości urn, wyniki bardziej się rozpraszają, a ich fluktuacja jest większa. Dla mniejszych ilości urn wyniki są bardziej skupione wokół średniej.

2) $u(n)$ - z wykresu możemy odczytać, że średnia liczba pustych urn po wrzuceniu określonej ilości kul rośnie liniowo wraz ze wzrostem n (co możemy odczytać z wykresu $u(n) / n$ - wartości średnie na tym wykresie można aproksymować do stałej różnej od zera). Jest to zgodne z intuicją - zwiększenie ilości urn i brak zwiększenia ilości kul zwiększa ilość pustych urn po wykonaniu eksperymentu. Wszystkie wartości są mocno skupione wokół wartości średnich.

3) $c(n)$ i $d(n)$ - z wykresów możemy odczytać, że wraz ze wzrostem liczby n (urn) liczba potrzebnych rzutów, aby osiągnąć określone warunki, rośnie w tempie $n \ln n$. Dla $c(n)$ (liczba rzutów potrzebnych, aby w każdej urnie była co najmniej jedna kulka) obserwujemy, że aproksymując wykres $c(n)/(n \ln n)$, wartość pozostaje stała i różna od zera. Podobną zależność widzimy dla $d(n)$ (liczba rzutów potrzebnych, aby w każdej urnie były co najmniej dwie kule), gdzie aproksymacja $d(n)/(n \ln n)$ również pokazuje stałą wartość różną od zera.

Dodatkowo, dla większych wartości n , wyniki zarówno $c(n)$, jak i $d(n)$ są bardziej rozproszone wokół średniej, a fluktuacje wyników są większe. Natomiast dla mniejszych wartości n , wyniki są bardziej skupione wokół średniej, co wskazuje na mniejszą zmienność w mniejszych próbach.

4) $d(n) - c(n)$ - z wykresu możemy odczytać, że wraz ze wzrostem liczby n (urn) różnica $d(n)$ i $c(n)$ rośnie, aczkolwiek ciężko jednoznacznie określić asymptotykę funkcji. Z wykresów $(d(n) - c(n)) / (n \ln n)$ i $(d(n) - c(n)) / (n \ln \ln n)$ możemy odczytać, że aproksymując ułożenie wartości średnich otrzymujemy wartość stałą, różną od zera. Na tej podstawie możemy założyć, że asymptotyka $d(n) - c(n)$ to $n \ln n$ lub $n \ln \ln n$. Dla mniejszych wartości n , wyniki są bardziej skupione wokół średniej, natomiast dla większych wartości wyniki są bardziej rozproszone wokół średniej.

Birthday paradox - paradoks związany z rachunkiem prawdopodobieństwa. Odpowiada na pytanie, ile potrzeba zgromadzić osób, aby prawdopodobieństwo znalezienia dwóch z taką samą datą urodzin (dzień i miesiąc) wynosiło $\frac{1}{2}$? Większość osób na to pytanie odpowiada, że ilość osób powinna wynosić $366 / 2 = 183$. Poprawną odpowiedzią na to pytanie jest 23 - zaskakująco mała liczba, stąd paradoks w nazwie. W naszym zadaniu wyznaczenie $b(n)$ jest równoważne birthday paradox, na wykresie przedstawiającym tę funkcję możemy zauważyć, że moment pierwszej kolizji następował -zazwyczaj- znacznie szybciej niż wynosi połowa n .

Cupon collector's problem - problem probabilistyczny polegający na przewidzeniu jak długo należy zbierać kupony, aby zebrać je wszystkie. Zebranie jednego kuponu polega na wylosowaniu go. W naszym zadaniu wyznaczenie $c(n)$ jest równoważne problemowi kolekcjonera kuponów - zliczamy po ilu rzutach w każdej urnie będzie znajdować się co najmniej jedna kulka.

Jakie znaczenie ma birthday paradox w kontekście funkcji hashujących i kryptograficznych funkcji hashujących?

Funkcje hashujące mapują dużą ilość danych wejściowych do skończonego zakresu wartości. Ze względu na ograniczony zakres możliwych hash, zgodnie z zasadą szufladkową Dirichleta, kolizje są nieuniknione. Birthday paradox pozwala oszacować po jakim czasie dojdzie do pierwszej kolizji przy losowych próbach.

Kryptograficzne funkcje hashujące mają kluczowe znaczenie w kontekście bezpieczeństwa systemów informatycznych. Paradoks urodzinowy wpływa na:

Atak urodzinowy: jego celem jest znalezienie kolizji funkcji hashujących. U jego podstaw leży birthday paradox, dzięki któremu można oczekiwać, że kolizja zostanie znaleziona znacznie szybciej niż sugerowałby to rozmiar przeciwdziedziny funkcji hashującej.

Projektowanie funkcji hashującej: funkcja hashująca powinna być (w miarę możliwości) odporna na atak urodzinowy. Algorytm powinien być zaprojektowany w taki sposób, aby skutecznie generować losowy rozkład wyników hash, minimalizując ryzyko kolizji.



















