

**Wojciech Typer**  
279730

Kody źródłowe, wykresy i histogramy zostały napisane w języku Python. Do obliczeń wykorzystano biblioteki NumPy i SciPy.


**zadanie 1**



n	Markov Bound	$P(X \geq 6/5 E(X))$	Chebyshev Bound	$P( X - E(X)  \geq 1/10 E(X))$
100	0.8333...	2.84E-02	1	3.68E-01
1000	0.8333...	1.36E-10	0.1	1.73E-03
10000	0.8333...	0	0.01	1.55E-23 ~ 0.0



Powyższa tabela przedstawia wynik pierwszego zadania. Markov Bound to prawa strona nierówności Markowa -  $E(X) / a$  - czyli w kontekście zadania  $E(X) / (6/5 * E(X)) = 5/6 \sim 0.8333$ . Chebyshev Bound to analogicznie, prawa strona nierówności Czebyszewa -  $\text{var}(x) / a^2$ , czyli w kontekście naszego zadania,  $\text{var}(x) / (0.1E(x))^2 = np(1-p) / (0.01(np)^2) = 1-p / 0.01np = 100/n$ .



Z tabeli wyników możemy odczytać, że nierówności Markowa i Czebyszewa zostały zachowane, gdyż prawe ich strony (Markov Bound i Chebyshev Bound) są większe niż rzeczywiste prawdopodobieństwo wystąpienia danych zdarzeń. Widzimy również, że dokładniejsze oszacowanie daje nierówność Czebyszewa.

**zadanie 2**



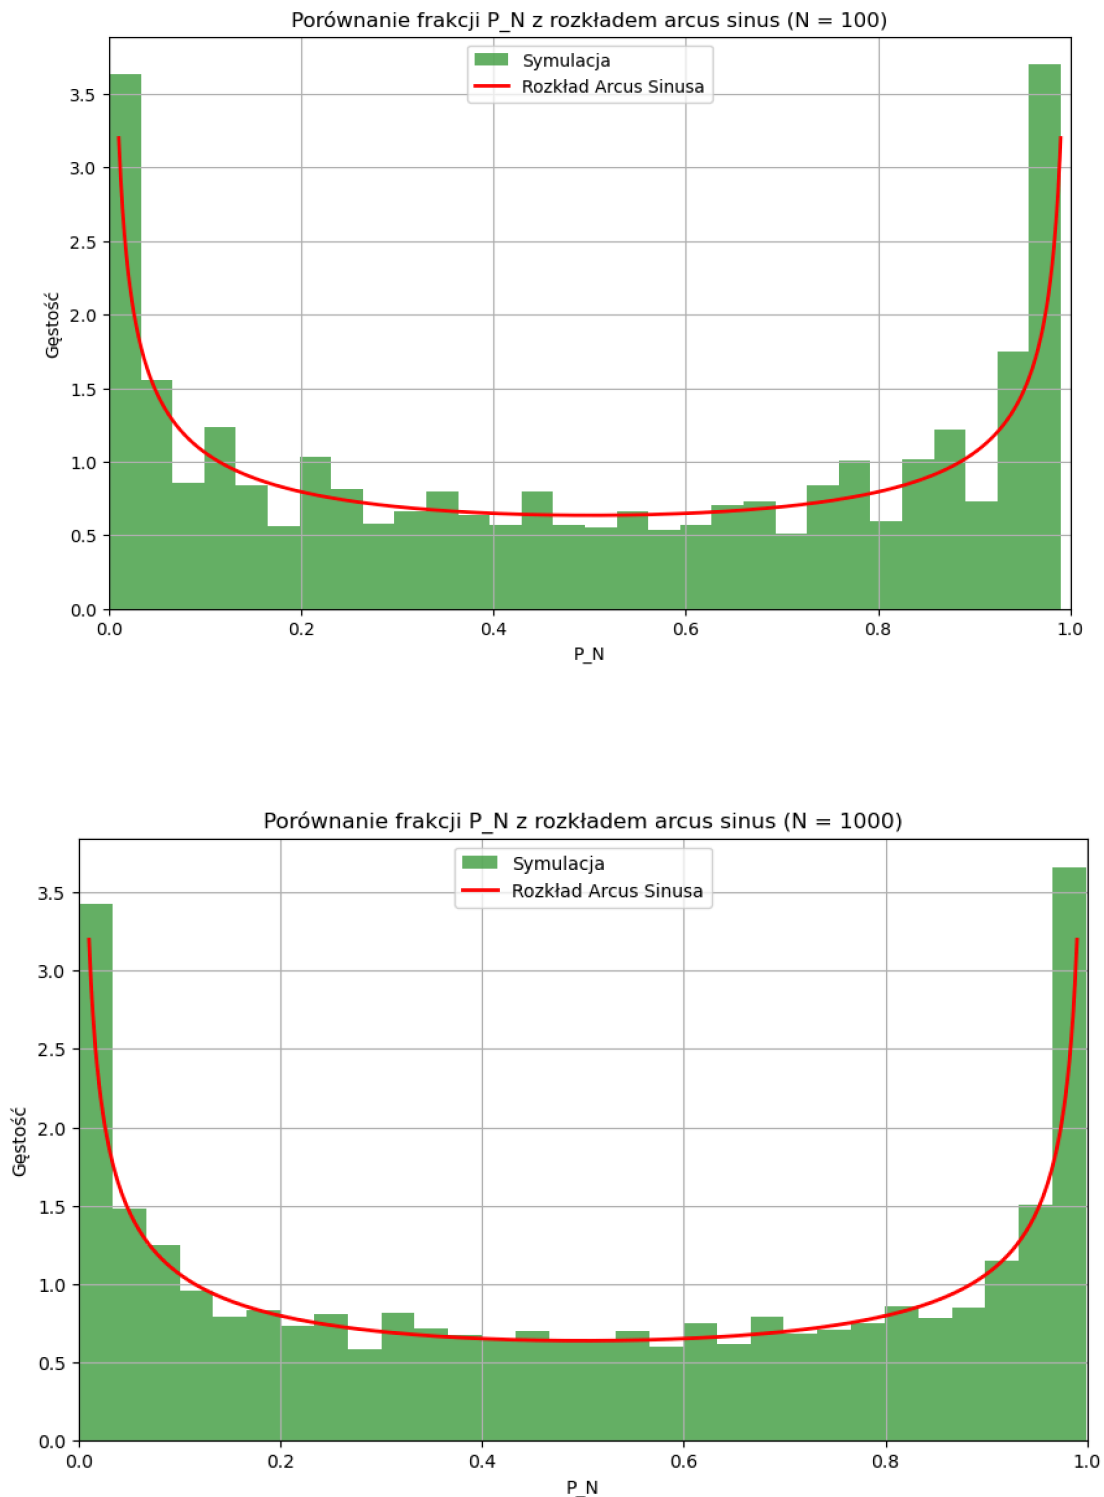







Z wykresów możemy odczytać, że dla coraz większych  $N$ , dystrybucja empiryczna coraz bardziej przypomina dystrybucję rozkładu normalnego. Jest to zgodne z Centralnym Twierdzeniem Granicznym, które mówi, że suma niezależnych zmiennych losowych o skończonych wariancjach zbiega w rozkładzie do rozkładu normalnego. W naszym przypadku  $S_n$  (suma niezależnych zmiennych losowych  $X_i$  o wartościach  $\pm 1$ ) coraz lepiej aproksymuje rozkład normalny, co szczególnie widać dla dużych wartości  $N$ .

### zadanie 3





Z histogramów możemy odczytać, że proces błędzenia losowego ma tendencję do znajdowania się większość czasu po jednej ze stron od osi OX - pod nią lub nad nią. Świadczy o tym fakt, że im bardziej skrajna wartość, tym słupek jest wyższy - niskie słupki w środkowej części histogramu wskazują, że proces rzadko kiedy spędzał równą część czasu po dwóch stronach osi OX. Zauważyć możemy również, że  $P_n = 0.5$  jest swego rodzaju osią symetrii histogramu, co jest zgodne z wcześniejszymi wnioskami. Dodatkowo, im większa liczba N, tym bardziej zauważalna jest koncentracja wartości  $P_n$  przy krańcach histogramu. Jest to zgodne z obserwacjami z wcześniejszych list zadań i przewiduje większą stabilność wyników dla coraz to większych liczb przeprowadzenia symulacji.

Dla dużych N wykres coraz bardziej przybliża wykres gęstości rozkładu arcusa sinusa (o parametrach  $a = b = 0.5$ ). Gęstość rozkładu arcusa sinusa wyrażona jest wzorem:

$$f(x) = \frac{1}{\pi \sqrt{x(1-x)}}$$

i odpowiada wartościom przedstawionym na wykresie:  $\lim_{x \rightarrow 0} f(x) = \lim_{x \rightarrow 1} f(x) = \infty$